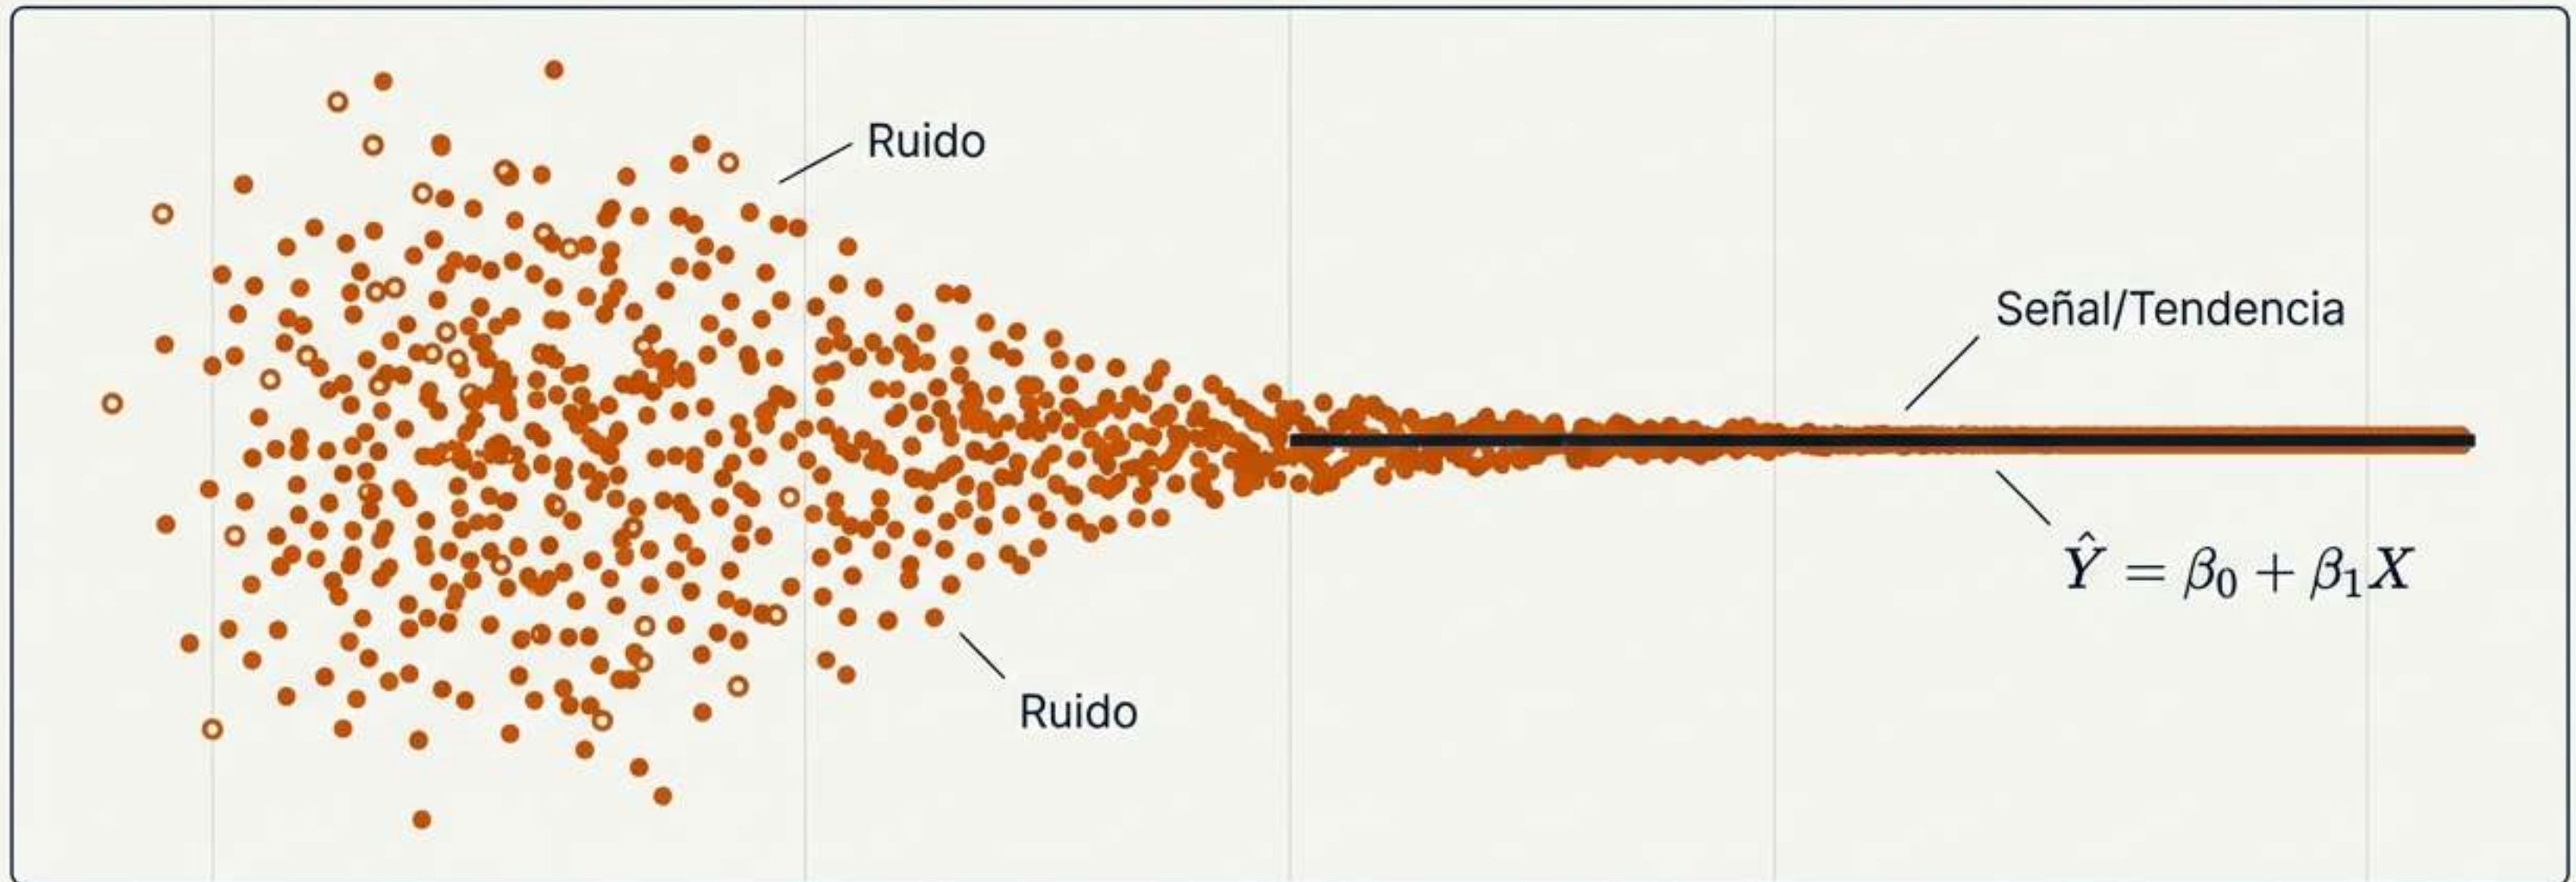


# Más allá del Promedio: Entendiendo la Regresión Lineal Simple

De la intuición gráfica a la precisión matemática: una guía para descifrar el ruido.





# La Pregunta de Negocio: ¿La publicidad realmente impulsa las ventas?



Analizamos 200 mercados distintos. El objetivo es cuantificar el retorno de inversión.

## Las 7 Preguntas del Detective:

1. ¿Cuál es la relación entre el presupuesto y las ventas?
2. ¿Existen otros factores que influyen?
3. ¿Cómo se comportan las ventas sin inversión?
4. **¿Con qué precisión podemos predecir las ventas futuras?**
5. ¿Cuál es el punto de saturación de la publicidad?
6. ¿Existen diferencias entre los mercados?
7. ¿Qué riesgos debemos considerar?

**La Interrogante Principal:** Si invertimos \$1,000 adicionales en TV, ¿cuántas unidades exactas venderemos?



# El Enfoque Detectivesco: Exploración de Datos

Antes de modelar, medimos la 'pista' inicial.

## Covarianza ( $S_{xy}$ )

Indica la dirección.

Positiva = crecen juntas.

Negativa = inversa.

*Defecto:* Depende de las unidades de medida.

## Correlación de Pearson ( $r_{xy}$ )


La medida estandarizada.

Elimina el efecto de escala.


$$r_{xy} = \frac{S_{xy}}{S_x S_y}$$




# Reconocimiento de Patrones: Ver antes de Calcular




**1. Determinístico**  
(Irreal)



**2. Lineal Ruidoso**  
(Regresión Simple)



**3. No Lineal**  
(Requiere Curvas)



**4. Segmentado**  
(Requiere Clasificación)

*La regresión lineal asume que una línea recta es la mejor descripción de la realidad.  
Si los datos dicen 'curva', la línea miente.*



# La Anatomía del Modelo

**Variable Respuesta (Ventas).**  
Lo que predecimos.

$$Y = \beta_0 + \beta_1 X + \epsilon$$

**La Señal (Componente Determinístico).**  
Parámetros constantes desconocidos.

**El Ruido (Error (Error Aleatorio)).**  
Incertidumbre y variables ocultas.

El objetivo es encontrar los valores de  $\beta_0$  y  $\beta_1$  que separan la señal del ruido.

# Las Reglas del Juego: Supuestos Fundamentales


Para que el modelo sea válido, el error ( $\epsilon$ ) debe comportarse de forma predecible.



## 1. Media Cero.

$$E(\epsilon) = 0.$$


Los errores no tienen sesgo; flotan equilibrados alrededor de la línea.



## 2. Homocedasticidad.

Varianza constante ( $\sigma^2$ ).

El error no crece cuando X crece.



## 4. Independencia.

El error de hoy no predice el error de mañana.



## 3. Normalidad.

$$\epsilon \sim N(0, \sigma^2).$$

El ruido sigue una distribución normal.




# Interpretando la Realidad: ¿Qué significan los parámetros?

$$\beta_0$$

## El Intercepto / Punto de Partida

Valor esperado de  $Y$  cuando  $X = 0$ .


**Ejemplo:** Ventas base sin inversión en publicidad.  
(A veces es teórico: ¿Estatura con edad 0?).



$$\beta_1$$

## La Pendiente / Tasa de Cambio

Cambio promedio en  $Y$  por cada unidad extra de  $X$ .



**Positiva (+):** Inversión sube, Ventas suben.

# El Reto de la Estimación

¿Cómo encontramos la “línea verdadera” entre infinitas posibilidades?

Datos de la Muestra ( $x, y$ )

## Estimación Heurística

El Ojómetro. Subjetivo.

## Máxima Verosimilitud (MLE)

Probabilístico. Maximizar  
chance de observar los datos.

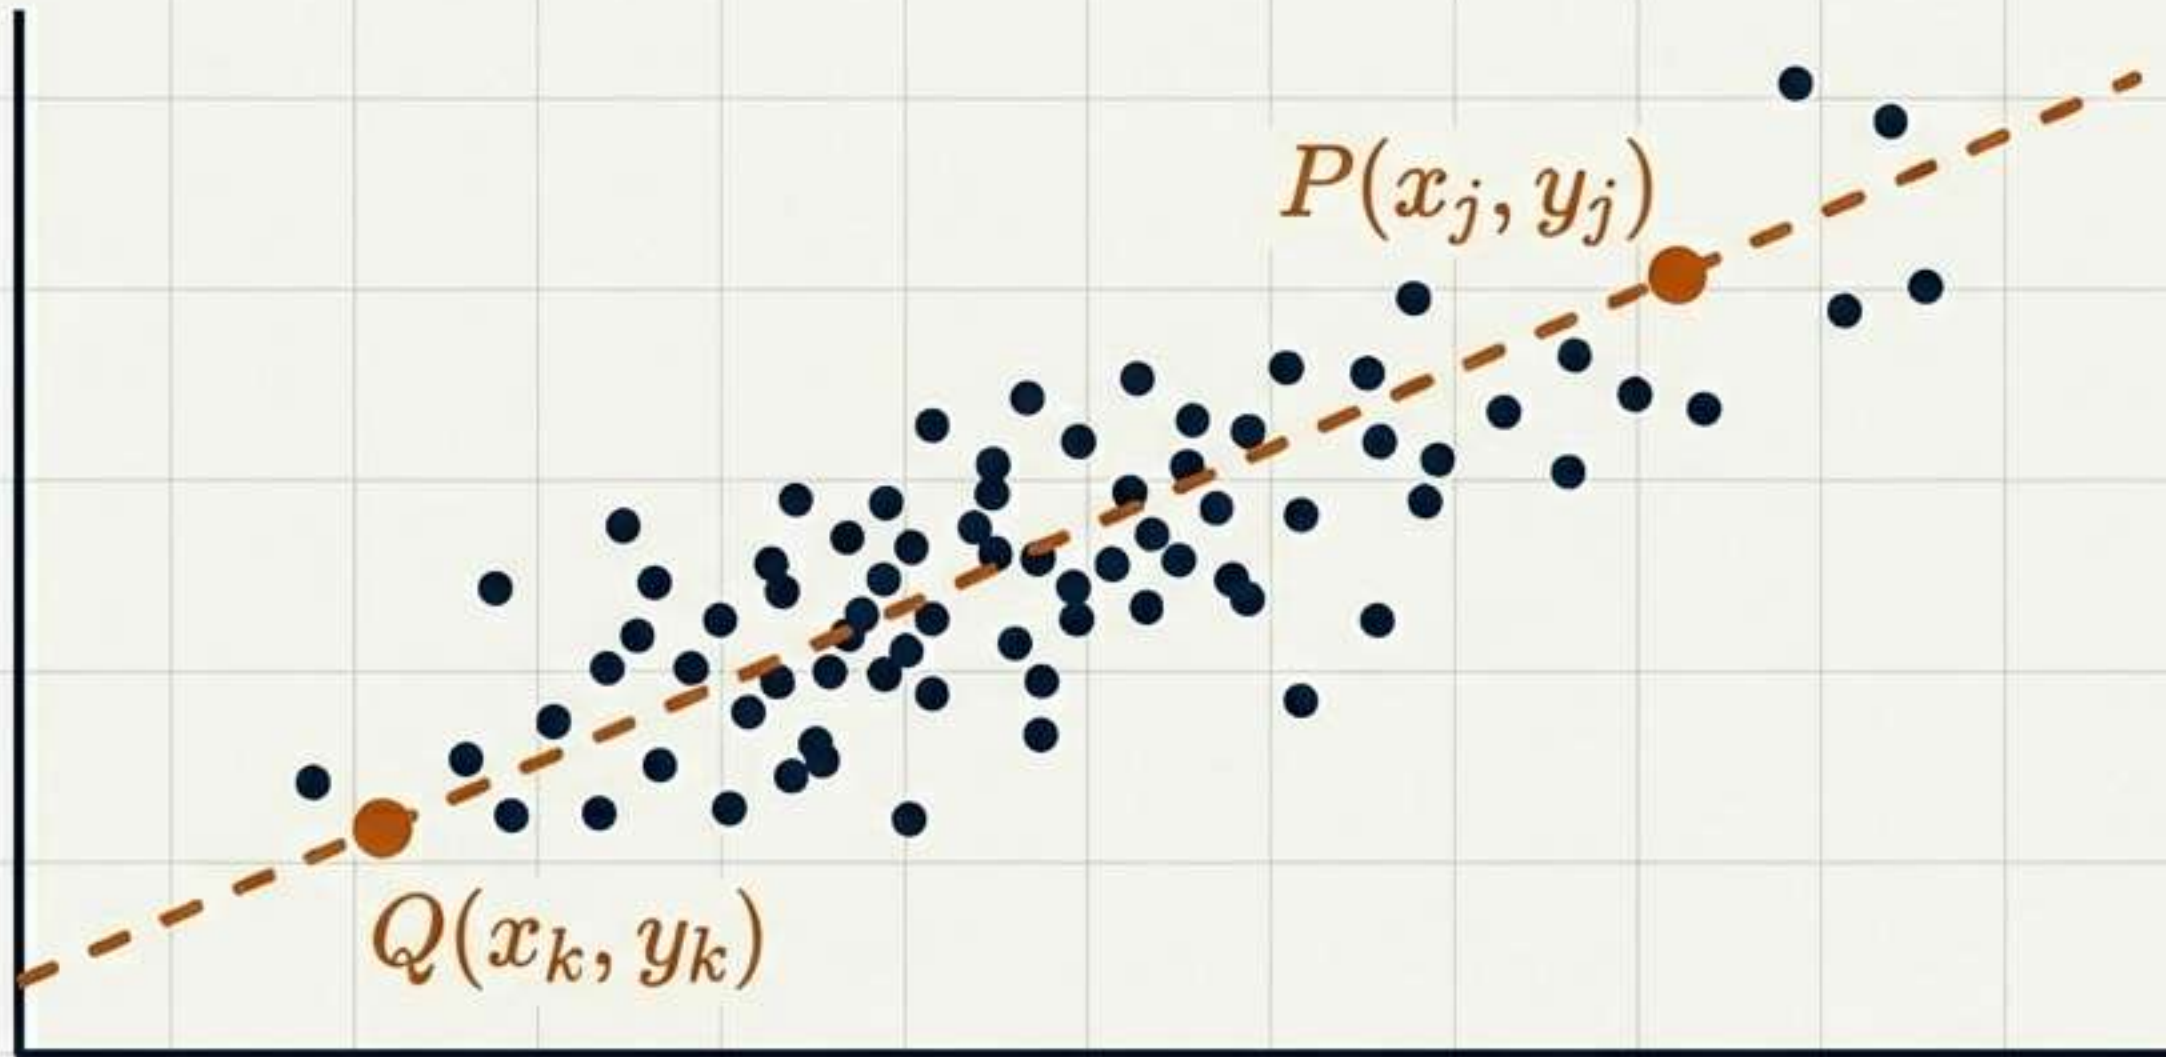
## Mínimos Cuadrados (OLS)

Geométrico. Minimizar  
distancia física.

Exploraremos los tres caminos.



# Método 1: Estimación Heurística (El “Ojómetro”)



Seleccionamos dos puntos representativos.

Calculamos la pendiente manualmente:

$$\tilde{\beta}_1 = \frac{y_j - y_k}{x_j - x_k}$$

**\*\*Veredicto:** Rápido e intuitivo, pero inestable.  
Depende subjetivamente de qué puntos elija el observador.



# Método 2: Máxima Verosimilitud (Probabilístico)


Buscamos los parámetros ( $\beta$ ) que hacen matemáticamente más probable haber observado estos datos específicos.

$$l(\beta_0, \beta_1, \sigma^2) = -\frac{n}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$$

1. Derivamos parcialmente respecto a  $\beta_0$  y  $\beta_1$ .
2. Igualamos a cero para encontrar el máximo.
3. Resultado: Genera las **Ecuaciones Normales**.



# Método 3: Mínimos Cuadrados Ordinarios (Geométrico)



**Goal:** Minimizar la Suma de los Residuos al Cuadrado (**RSS**).

$$RSS = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

**Why Squares?**

- Penaliza severamente los errores grandes.
- Evita que errores positivos y negativos se cancelen.



# La Convergencia: El Veredicto Matemático

Bajo el supuesto de normalidad, Máxima Verosimilitud y Mínimos Cuadrados producen **exactamente el mismo resultado**.

Pendiente ( $\hat{\beta}_1$ ): 
$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}} = r_{xy} \frac{S_y}{S_x}$$

**Covarianza normalizada** por varianza de X

Intercepto ( $\hat{\beta}_0$ ): 
$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

La línea **pivota** sobre el promedio  $(\bar{x}, \bar{y})$



# Aplicación: Resultados del Caso Advertising

**Datos:** 200 Mercados (TV vs Ventas)

**Cálculo de Parámetros:**

$$\hat{\beta}_0 = 7.03$$

$$\hat{\beta}_1 = 0.0475$$

$$Ventas = 7.03 + 0.0475 \times TV \text{ Budget}$$

## Interpretación

### El Intercepto:

Sin publicidad, vendemos **7,030** unidades base.


### La Pendiente:

Por cada **\$1,000** extra en TV, vendemos **47.5** unidades adicionales.



# Diagnóstico y Cautela: No confíe ciegamente

1. **Extrapolación:** Peligroso predecir fuera del rango observado. No sabemos si la línea continúa.
2. **Datos Influyentes:** Un solo 'outlier' puede distorsionar toda la pendiente (ver gráfico).
3. **Análisis de Residuos:** Verifique los errores. Si ve patrones (curvas, embudos), el modelo lineal no es suficiente.





# Resumen Ejecutivo: El Poder de la Simplificación



**Los modelos lineales son herramientas poderosas no porque sean perfectos, sino porque simplifican la complejidad para permitir la toma de decisiones.**




ESTADÍSTICA COMPUTACIONAL AVANZADA

Editorial Mathematics

# Modelos de Regresión Simple: Estimación y Diagnóstico

De la intuición geométrica a la formulación matricial.





# El Objetivo de la Predicción


Buscamos un estimador puntual de la media de  $Y$  para un  $x$  fijo.

La ecuación de predicción:

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$$




Forma centrada:

$$\hat{y}_i = \bar{y} + \hat{\beta}_1 (x_i - \bar{x})$$





# Geometría del Error: ¿Qué distancia minimizamos?



Para estimar la media de  $Y$  dado  $x$ , el método de Mínimos Cuadrados Ordinarios (MCO) utiliza exclusivamente la **Distancia Vertical**.




# El Método de Mínimos Cuadrados Ordinarios (MCO)

Función a minimizar (D):

$$D(\beta_0, \beta_1) = \sum_{i=1}^n \epsilon_i^2 = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$$

Elevamos al cuadrado para penalizar las grandes desviaciones y evitar que los errores positivos y negativos se cancelen.



# La Derivación de los Estimadores

## 1. Derivadas Parciales = 0

$$\frac{\partial D}{\partial \beta_0} = -2 \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) = 0$$

$$\frac{\partial D}{\partial \beta_1} = -2 \sum_{i=1}^n x_i (y_i - \beta_0 - \beta_1 x_i) = 0$$

La matriz Hessiana es definida positiva, asegurando un mínimo global.

## 2. Ecuaciones Normales

$$\begin{aligned} n\hat{\beta}_0 + \hat{\beta}_1 \sum x_i &= \sum y_i \\ \hat{\beta}_0 \sum x_i + \hat{\beta}_1 \sum x_i^2 &= \sum x_i y_i \end{aligned}$$

## 3. Solución Escalar

$$\hat{\beta}_1 = \frac{\text{Cov}(x, y)}{\text{Var}(x)}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$



# Traducción al Lenguaje Matricial

Anatomy of the Equation

$$Y = X\beta + \epsilon$$

The diagram illustrates the matrix representation of the linear regression equation  $Y = X\beta + \epsilon$ . Each term is mapped to a specific matrix structure and dimensions:

- $Y$  is represented as a column vector  $\begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}$  with dimensions  $n \times 1$  (Respuesta).
- $X$  is represented as a design matrix  $\begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{bmatrix}$  with dimensions  $n \times 2$  (Matriz de Diseño). The first column, containing ones, is highlighted in orange and labeled "Intercepto" with an arrow.
- $\beta$  is represented as a parameter vector  $\begin{bmatrix} \beta_0 \\ \beta_1 \end{bmatrix}$  with dimensions  $2 \times 1$  (Parámetros).
- $\epsilon$  is represented as an error vector  $\begin{bmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_n \end{bmatrix}$  with dimensions  $n \times 1$  (Errores).

# La Solución Elegante

Minimizar la suma de cuadrados en forma matricial:

$$D(\beta) = (Y - X\beta)'(Y - X\beta)$$



Derivando respecto a  $\beta$ :

$$-2X'Y + 2X'X\beta = 0$$



Ecuaciones Normales:

$$X'X\beta = X'Y$$

$$\hat{\beta} = (X'X)^{-1}X'Y$$

**Condición:** La matriz  $(X'X)$  debe ser no singular (invertible).



# Coeficiente de Determinación ( $R^2$ )

Variabilidad Total (SCT)



$$SCT = SCM + SCE$$



Variabilidad Explicada (SCM)

Ruido / Error (SCE)

$$R^2 = \frac{SCM}{SCT} = 1 - \frac{SCE}{SCT}$$

Proporción de la variabilidad de Y explicada por el modelo lineal.  $0 \leq R^2 \leq 1$ .

# $R^2$ Ajustado vs. Estándar

## $R^2$ Estándar

**El problema:** Nunca disminuye al agregar variables, aunque sean irrelevantes.

Estatura Hijo-Padre

$$R^2 = \mathbf{0.9415}$$

## $R^2$ Ajustado

**La solución:** Penaliza la complejidad (número de parámetros  $p$ ).

$$R_{adj}^2 = 1 - \frac{SCE/(n - p)}{SCT/(n - 1)}$$

Estatura Hijo-Padre

$$R_{adj}^2 = \mathbf{0.9332}$$

El ajuste corrige los grados de libertad. Si el modelo es parsimonioso, ambos valores deben ser cercanos.



# Análisis de los Residuos: La Huella del Modelo

## Residuo: $e_i = y_i - \hat{y}_i$

Suma Cero

$$\rightarrow \sum e_i = 0$$

Ortogonalidad

$$\rightarrow \sum e_i x_i = 0$$

Key Metric (Varianza Residual)

$$\hat{\sigma}_R^2 = \frac{\sum e_i^2}{n - 2}$$

Grados de libertad  
(perdemos **2** al  
estimar  $\beta_0$  y  $\beta_1$ ).