



Neurona biológica



Plasticidad: capacidad del sistema nervioso para cambiar su estructura y su funcionamiento a lo largo de su vida, como reacción a los cambios del entorno. Permite a las neuronas regenerarse tanto anatómica como funcionalmente y formar nuevas conexiones sinápticas.

La neurona artificial

Actualmente, una neurona artificial se visualiza como un procesador elemental que ejecuta dos funciones:



h = función de entrada


$f(h)$ = función de activación

Las señales son propagadas de una neurona a otra mediante reacciones electroquímicas complejas.

Las sustancias químicas liberadas de las sinapsis causan un cambio en el potencial eléctrico del cuerpo celular.

Cuando el potencial alcanza un umbral, se produce un impulso eléctrico que se envía a través del axón.

Importante: Las redes neuronales exhiben plasticidad.



$$h = w_1 \times x_1 + w_2 \times x_2 + \dots + w_d \times x_d$$

$$h = \mathbf{w} \cdot \mathbf{x}$$

- Si la función de activación es lineal:

$$f(h) = h \Rightarrow y = w_1 \times x_1 + w_2 \times x_2 + \dots + w_d \times x_d$$

¡Regresión lineal!


- Si la función de activación es la logística:

$$f(h) = \frac{1}{1 + e^{-(h)}} \Rightarrow y = \text{función}_{\text{logística}}(w_1 \times x_1 + w_2 \times x_2 + \dots + w_d \times x_d)$$

¡Regresión logística!

Cambiando la función de activación se obtienen diferentes comportamientos


- Para el problema de estimación de CO2 se tendría:



La Adaline (Adaptative Linear Neuron) de Bernard Widroff y Marcian Hoff en 1960 :


$h = \text{función de entrada} = \mathbf{w} \cdot \mathbf{x} + b \rightarrow f(h) = h$
 $f = \text{función de activación} = \text{identidad o lineal}$

- Para problemas de regresión.



Modelo lineal

- Para el problema sobre enfermedades cardiovasculares se tendría :




El perceptrón de Frank Rosenblatt (1957)

$h = \text{función de entrada} = \mathbf{w} \cdot \mathbf{x} + b$

$f = \text{función de activación} = \text{escalón o umbral}$

$$\rightarrow f(h) = \begin{cases} 1 & \text{si } h \geq 0 \\ 0 & \text{si } h < 0 \end{cases}$$

- Para problemas de clasificación.



Modelo lineal

Ejemplo. Detección de correos SPAM.

Conjunto de datos = $\{\mathbf{x}_j, y_j\}_{j=1..N}$

x_{j1} = frecuencia palabra 1

x_{j2} = frecuencia palabra 2


x_{j3} = frecuencia palabra 3

$y_j \in \{0,1\}$ = clases $\begin{cases} 1 \rightarrow \text{Spam} \\ 0 \rightarrow \text{No Spam} \end{cases}$

x_1	x_2	x_3	Clase (y)



Arquitectura de la red neuronal



Una vez inicializada la red neuronal y especificadas las funciones de activación en cada capa, se tiene:

$$\mathbf{W}^{(1)} = \begin{bmatrix} 0.3 & 0.2 & 0.3 \\ 0.1 & 0.1 & 0.2 \\ 0.2 & 0.1 & 0.1 \end{bmatrix} \quad \mathbf{b}^{(1)} = \begin{bmatrix} 0.1 \\ 0.3 \\ 0.1 \end{bmatrix} \quad f^1 = \text{Sigmoide}$$

$$\mathbf{W}^{(2)} = \begin{bmatrix} 0.3 & 0.3 & -0.1 \end{bmatrix} \quad \mathbf{b}^{(2)} = \begin{bmatrix} 0.1 \end{bmatrix} \quad f^2 = \text{sigmoide}$$

¿Cuál es la salida de la red para el siguiente dato?

$$\mathbf{x} = \begin{bmatrix} 3 \\ 1 \\ 4 \end{bmatrix}$$

Primera capa:

$$z_1^{(1)} = f^{(1)} \left(w_{11}^{(1)} \times x_1 + w_{12}^{(1)} \times x_2 + w_{13}^{(1)} \times x_3 + b_1^{(1)} \right) = f_{\text{sigmoide}}(0.3 \times 3 + 0.2 \times 1 + 0.3 \times 4 + 0.1) = f_{\text{sigmoide}}(2.4) = 0.91$$


$$z_2^{(1)} = f^{(1)} \left(w_{21}^{(1)} \times x_1 + w_{22}^{(1)} \times x_2 + w_{23}^{(1)} \times x_3 + b_2^{(1)} \right) = f_{\text{sigmoide}}(0.1 \times 3 + 0.1 \times 1 + 0.2 \times 4 + 0.3) = f_{\text{sigmoide}}(1.5) = 0.81$$

$$z_3^{(1)} = f^{(1)} \left(w_{31}^{(1)} \times x_1 + w_{32}^{(1)} \times x_2 + w_{33}^{(1)} \times x_3 + b_3^{(1)} \right) = f_{\text{sigmoide}}(0.2 \times 3 + 0.1 \times 1 + 0.1 \times 4 + 0.1) = f_{\text{sigmoide}}(1.2) = 0.76$$

Segunda capa:


$$y_1^{(2)} = f^{(2)} \left(w_{11}^{(2)} \times z_1^{(1)} + w_{12}^{(2)} \times z_2^{(1)} + w_{13}^{(2)} \times z_3^{(1)} + b_1^{(2)} \right) = f_{\text{sigmoide}}(0.3 \times 0.91 + 0.3 \times 0.81 - 0.1 \times 0.76 + 0.1) = f_{\text{sigmoide}}(0.54) = 0.63$$

$$\mathbf{x} = \begin{bmatrix} 3 \\ 1 \\ 4 \end{bmatrix}$$



A través de la capa oculta

$$\mathbf{y}^{(1)} = \mathbf{z} = \begin{bmatrix} 0.91 \\ 0.81 \\ 0.76 \end{bmatrix}$$



De manera matricial:


$$\begin{bmatrix} z_1 \\ z_2 \\ z_3 \end{bmatrix} = f^1 \left(\begin{bmatrix} 0.3 & 0.2 & 0.3 \\ 0.1 & 0.1 & 0.2 \\ 0.2 & 0.1 & 0.1 \end{bmatrix} \times \begin{bmatrix} 3 \\ 1 \\ 4 \end{bmatrix} + \begin{bmatrix} 0.1 \\ 0.3 \\ 0.1 \end{bmatrix} \right) = \begin{bmatrix} 0.91 \\ 0.81 \\ 0.76 \end{bmatrix}$$

$$\hat{y} = f^2 \left([0.3 \quad 0.3 \quad -0.1] \times \begin{bmatrix} z_1 \\ z_2 \\ z_3 \end{bmatrix} + [0.1] \right) = f^2 \left([0.3 \quad 0.3 \quad -0.1] \times \begin{bmatrix} 0.91 \\ 0.81 \\ 0.76 \end{bmatrix} + [0.1] \right) = f^2 [0.54] = \mathbf{0.63}$$

Entonces,

x_1	x_2	x_3	Spam
3	1	4	1

$$\rightarrow \mathbf{x} = \begin{bmatrix} 3 \\ 1 \\ 4 \end{bmatrix}$$



¿Cómo resolver una tarea de regresión?

Análisis del problema

El cambio climático se refiere tanto al calentamiento global provocado por la emisión de gases de efecto invernadero por parte del hombre, como al aumento de los desastres ambientales inducidos por dicho calentamiento. En particular, en el caso del dióxido de carbono (CO₂), aunque es necesario para la vida en el planeta, su exceso de concentración provoca el “efecto invernadero”, que eleva la temperatura del planeta y desequilibra el ciclo natural.

La emisión de CO₂ es mayor en los motores de gasolina, por lo que reducir las emisiones de la industria automovilística es uno de los grandes objetivos actuales. Conocer cómo las emisiones de CO₂ varían de acuerdo a las características del vehículo puede aportar al establecimiento de medidas que favorezcan la producción de aquellos menos contaminantes.

Recolección de datos

El conjunto de datos recoge los detalles de cómo las emisiones de CO₂ de un vehículo pueden variar con las diferentes características de este, como tamaño del motor, número de cilindros, consumo de combustible, entre otros. Ha sido tomado del sitio web oficial de datos abiertos del Gobierno de Canadá y contiene información de un periodo de 7 años.

Make	Model	Vehicle Class	Engine Size(L)	Cylinders	Transmission	Fuel Type	Fuel Consumption City (L/100 km)	Fuel Consumption Hwy (L/100 km)	Fuel Consumption Comb (L/100 km)	Fuel Consumption Comb (mpg)	CO2 Emissions(g/km)
ACURA	ILX	COMPACT	2	4	AS5	Z	9.9	6.7	8.5	33	196
ACURA	ILX	COMPACT	2.4	4	M6	Z	11.2	7.7	9.6	29	221
ACURA	ILX HYBRID	COMPACT	1.5	4	AV7	Z	6	5.8	5.9	48	136
ACURA	MDX 4WD	SUV - SMALL	3.5	6	AS6	Z	12.7	9.1	11.1	25	255
ACURA	RDX AWD	SUV - SMALL	3.5	6	AS6	Z	12.1	8.7	10.6	27	244
ACURA	RLX	MID-SIZE	3.5	6	AS6	Z	11.9	7.7	10	28	230
ACURA	TL	MID-SIZE	3.5	6	AS6	Z	11.8	8.1	10.1	28	232
ACURA	TL AWD	MID-SIZE	3.7	6	AS6	Z	12.8	9	11.1	25	255
ACURA	TL AWD	MID-SIZE	3.7	6	M6	Z	13.4	9.5	11.6	24	267
ACURA	TSX	COMPACT	2.4	4	AS5	Z	10.6	7.5	9.2	31	212
ACURA	TSX	COMPACT	2.4	4	M6	Z	11.2	8.1	9.8	29	225
ACURA	TSX	COMPACT	3.5	6	AS5	Z	12.1	8.3	10.4	27	239
ALFA ROMEO	4C	TWO-SEATER	1.8	4	AM6	Z	9.7	6.9	8.4	34	193
ASTON MARTIN	DB9	MINICOMPACT	5.9	12	A6	Z	18	12.6	15.6	18	359
ASTON MARTIN	RAPIDE	SUBCOMPACT	5.9	12	A6	Z	18	12.6	15.6	18	359
ASTON MARTIN	V8 VANTAGE	TWO-SEATER	4.7	8	AM7	Z	17.4	11.3	14.7	19	338
ASTON MARTIN	V8 VANTAGE	TWO-SEATER	4.7	8	M6	Z	18.1	12.2	15.4	18	354
ASTON MARTIN	V8 VANTAGE S	TWO-SEATER	4.7	8	AM7	Z	17.4	11.3	14.7	19	338
ASTON MARTIN	V8 VANTAGE S	TWO-SEATER	4.7	8	M6	Z	18.1	12.2	15.4	18	354
ASTON MARTIN	VANQUISH	MINICOMPACT	5.9	12	A6	Z	18	12.6	15.6	18	359
AUDI	A4	COMPACT	2	4	AV8	Z	9.9	7.4	8.8	32	202

No. De datos: 7368

No. de variables: 12
(incluida la variable target)

Propuesta: modelo de regresión para estimar las emisiones de CO2 con base en las características del vehículo.

Algoritmo a utilizar: regresión lineal.

Exploración de los datos

- Se obtiene un primer conocimiento de los datos.
- Proporciona información para determinar problemas de calidad en los datos.
- Ayuda a determinar si el conjunto de datos es adecuado para resolver el problema.
- Técnicas: perfilamiento de datos, gráficos (histogramas, diagramas de dispersión, diagramas de caja), análisis de correlación,...

- *¿Cuáles y cómo son los datos? ¿Significado de los atributos?*
- *¿Cuál es el rango de valores permitido para cada atributo? ¿Distribuciones de las variables?*
- *¿Existen valores ausentes? ¿Cómo se representan? ¿Con qué frecuencia se presentan? ¿Cuáles son las causas?*
- *¿Existen valores fuera de rango? ¿Valores extremos?*
- *¿Los datos son completos? ¿Cubren todos los casos?*
- *¿Cuando los datos provienen de diferentes fuentes ¿Los significados de los datos son iguales? ¿Tienen la misma unidad de medida?*
- *¿Existen datos redundantes? ¿Datos duplicados? ¿Los datos son consistentes?*
- *¿Existen variables correlacionadas?*
- *¿Cuáles son las reglas para manejar los datos nulos?*
- *En clasificación, ¿Cuál es la proporción de las clases? ¿Están desbalanceadas?, ...*

Limpieza y preparación

Algunos errores:

- Datos ausentes. El valor de la variable no se conoce para algunas instancias.
- Datos anómalos o fuera de rango.
- Datos inconsistentes. Para el dominio de aplicación.
- Datos duplicados,
- Importante: diccionario de los datos.

¿Qué se hace?

- Corrección de errores.
- Ingeniería de características
- Aumentación de datos, ...

Transformaciones
Selección de variables
Construcción(extracción de características)

Modelado

Variable dependiente = y

Make	Model	Vehicle Class	Engine Size(L)	Cylinders	Transmission	Fuel Type	Fuel Consumption City (L/100 km)	Fuel Consumption Hwy (L/100 km)	Fuel Consumption Comb (L/100 km)	Fuel Consumption Comb (mpg)	CO2 Emissions(g/km)
ACURA	ILX	COMPACT	2	4	AS5	Z	9.9	6.7	8.5	33	196
ACURA	ILX	COMPACT	2.4	4	M6	Z	11.2	7.7	9.6	29	221
ACURA	ILX HYBRID	COMPACT	1.5	4	AV7	Z	6	5.8	5.9	48	136
ACURA	MDX 4WD	SUV - SMALL	3.5	6	AS6	Z	12.7	9.1	11.1	25	255
ACURA	RDX AWD	SUV - SMALL	3.5	6	AS6	Z	12.1	8.7	10.6	27	244
ACURA	RLX	MID-SIZE	3.5	6	AS6	Z	11.9	7.7	10	28	230
ACURA	TL	MID-SIZE	3.5	6	AS6	Z	11.8	8.1	10.1	28	232
ACURA	TL AWD	MID-SIZE	3.7	6	AS6	Z	12.8	9	11.1	25	255
ACURA	TL AWD	MID-SIZE	3.7	6	M6	Z	13.4	9.5	11.6	24	267
ACURA	TSX	COMPACT	2.4	4	AS5	Z	10.6	7.5	9.2	31	212
ACURA	TSX	COMPACT	2.4	4	M6	Z	11.2	8.1	9.8	29	225
ACURA	TSX	COMPACT	3.5	6	AS5	Z	12.1	8.3	10.4	27	239
ALFA ROMEO	4C	TWO-SEATER	1.8	4	AM6	Z	9.7	6.9	8.4	34	193
ASTON MARTIN	DB9	MINICOMPACT	5.9	12	A6	Z	18	12.6	15.6	18	359
ASTON MARTIN	RAPIDE	SUBCOMPACT	5.9	12	A6	Z	18	12.6	15.6	18	359
ASTON MARTIN	V8 VANTAGE	TWO-SEATER	4.7	8	AM7	Z	17.4	11.3	14.7	19	338
ASTON MARTIN	V8 VANTAGE	TWO-SEATER	4.7	8	M6	Z	18.1	12.2	15.4	18	354
ASTON MARTIN	V8 VANTAGE S	TWO-SEATER	4.7	8	AM7	Z	17.4	11.3	14.7	19	338
ASTON MARTIN	V8 VANTAGE S	TWO-SEATER	4.7	8	M6	Z	18.1	12.2	15.4	18	354
ASTON MARTIN	VANQUISH	MINICOMPACT	5.9	12	A6	Z	18	12.6	15.6	18	359
AUDI	A4	COMPACT	2	4	AV8	Z	9.9	7.4	8.8	32	202

Objetivo: que el estimado $\hat{y}$ se aproxime al valor real tanto como sea posible.

$$\hat{y} \cong y$$

Por ahora, solo las variables numéricas

Algoritmo de regresión lineal

Modelo de regresión lineal

$$f: X \rightarrow \mathcal{R} / f(x) = \hat{y}$$

$$\hat{y} = w_0 + w_1 \times Engine + w_2 \times Cylinders + \dots + w_6 \times mpg$$

Parámetros del modelo

¿Cómo el algoritmo de aprendizaje selecciona la solución que mejor se ajusta a los datos?

Es decir, ¿cómo selecciona los valores de $w_0, w_1, \dots, w_d$ que dan lugar al hiperplano de mejor ajuste?

$$\text{Función de costo} = \frac{1}{N} \sum_{i=1}^N (\hat{y}_i - y_i)^2$$

El valor de la función de costo depende de los parámetros del modelo.

Función de costo: mide la discrepancia entre lo que predice el modelo y el valor real (error) para todos los datos.

Para regresión, la función más utilizada es el promedio de la suma de los errores al cuadrado o error cuadrático medio (MSE).

$$\text{Función de costo} = J(\mathbf{w}) = \frac{1}{N} \sum_{i=1}^N (\hat{y}_i - y_i)^2 = \frac{1}{N} \sum_{i=1}^N ((w_0 + w_1 \times x_i + w_2 \times x_2 + \dots + w_d \times x_d) - y_i)^2$$



Algoritmo de aprendizaje

Determina los valores de los parámetros $(w_0, w_1, \dots, w_d)$ que minimizan la función de costo.

¿Cómo resolver este problema de optimización?

¿Cómo resolver una tarea de clasificación?

Análisis del problema

Según la Organización Mundial de la Salud , las enfermedades cardiovasculares (ECV) son la principal causa de muerte en todo el mundo, y se estima que, para el 2030, 23,6 millones de personas morirán por alguna enfermedad de este tipo. Las ECV son un grupo de trastornos del corazón y de los vasos sanguíneos que incluyen, entre otras afecciones, a la enfermedad coronaria, enfermedad cerebrovascular y enfermedad cardíaca reumática. Cuatro de cada 5 muertes por ECV se deben a ataques cardíacos y accidentes cerebrovasculares, y un tercio de estas muertes ocurren prematuramente en personas menores de 70 años. Un pronóstico temprano podría ayudar a tomar decisiones sobre los cambios en el estilo de vida en pacientes de alto riesgo y, a su vez, reducir las complicaciones.

En este sentido, se quiere llevar a cabo un estudio, tomando como base los datos de los pacientes registrados en una institución médica, que utilice técnicas de machine learning para la construcción de modelos que, no solo aporten en la identificación de los factores que más inciden en el padecimiento de enfermedad cardíaca, sino también puedan predecir qué pacientes están en riesgo de sufrir una ECV.

Recolección de datos

Edad	Género	Altura	Peso	Presion sistólica	Presión diastólica	Colesterol	Glucosa	Fumador	Alcohol	Activo	ECV
53	M	168	62.0	110	80	Normal	Normal	NO	NO	SI	NO
58	F	156	85.0	140	90	Muy elevado	Normal	NO	NO	SI	SI
54	F	165	64.0	130	70	Muy elevado	Normal	NO	NO	NO	SI
50	M	169	82.0	150	100	Normal	Normal	NO	NO	SI	SI
50	F	156	56.0	100	60	Normal	Normal	NO	NO	NO	NO
63	F	151	67.0	120	80	Elevado	Elevado	NO	NO	NO	NO
63	F	157	93.0	130	80	Muy elevado	Normal	NO	NO	SI	NO
65	M	178	95.0	130	90	Muy elevado	Muy elevado	NO	NO	SI	SI
50	F	158	71.0	110	70	Normal	Normal	NO	NO	SI	NO
57	F	164	68.0	110	60	Normal	Normal	NO	NO	NO	NO
57	F	158	78.0	110	70	Normal	Normal	NO	NO	SI	NO
42	M	181	95.0	130	90	Normal	Normal	SI	SI	SI	NO
48	M	172	112.0	120	80	Normal	Normal	NO	NO	NO	SI
61	M	170	75.0	130	70	Normal	Normal	NO	NO	NO	NO
57	M	163	83.0	120	80	Normal	Normal	NO	NO	SI	NO
61	F	157	69.0	130	80	Normal	Normal	NO	NO	SI	NO
66	F	158	90.0	145	85	Elevado	Elevado	NO	NO	SI	SI

⋮

Número de datos: 69.997

Número de variables: 12

Objetivos:

- Predecir qué pacientes están en riesgo de sufrir una ECV
- Identificar los factores que más inciden en el padecimiento de enfermedad cardíaca.

Propuesta: para alcanzar el primer objetivo se puede realizar una tarea de clasificación que utilice como variable target “ECV”, la cual indica la presencia o ausencia de enfermedad cardiovascular. Dependiendo del algoritmo a utilizar se podría hacer un análisis de las variables más significativas, lo cual podría permitir alcanzar el segundo objetivo. O utilizar alguna librería que permita realizar una interpretación del modelo.

Modelado


Edad	Género	Altura	Peso	Presión sistólica	Presión diastólica	Colesterol	Glucosa	Fumador	Alcohol	Activo	ECV
53	M	168	62.0	110	80	Normal	Normal	NO	NO	SI	0
58	F	156	85.0	140	90	Muy elevado	Normal	NO	NO	SI	1
54	F	165	64.0	130	70	Muy elevado	Normal	NO	NO	NO	1
50	M	169	82.0	150	100	Normal	Normal	NO	NO	SI	1
50	F	156	56.0	100	60	Normal	Normal	NO	NO	NO	0
63	F	151	67.0	120	80	Elevado	Elevado	NO	NO	NO	0
63	F	157	93.0	130	80	Muy elevado	Normal	NO	NO	SI	0
65	M	178	95.0	130	90	Muy elevado	Muy elevado	NO	NO	SI	1
50	F	158	71.0	110	70	Normal	Normal	NO	NO	SI	0
57	F	164	68.0	110	60	Normal	Normal	NO	NO	NO	0
64	F	169	80.0	120	80	Normal	Normal	NO	NO	SI	0
54	M	173	60.0	120	80	Normal	Normal	NO	NO	SI	0
42	M	165	60.0	120	80	Normal	Normal	NO	NO	NO	0
57	F	158	78.0	110	70	Normal	Normal	NO	NO	SI	0
42	M	181	95.0	130	90	Normal	Normal	SI	SI	SI	0
48	M	172	112.0	120	80	Normal	Normal	NO	NO	NO	1
61	M	170	75.0	130	70	Normal	Normal	NO	NO	NO	0
48	M	158	52.0	110	70	Normal	Muy elevado	NO	NO	SI	0

Objetivo: que la clase estimada se aproxime al valor real tanto como sea posible.

Algoritmo de clasificación

Modelo de clasificación

ECV = "1" ⇒ Sí
ECV = "0" ⇒ NO



El vector w siempre apunta a la región donde la clase es 1.

$$\text{Clase estimada} = f_{\text{umbral}}(w_0 + w_1x_1 + w_2x_2)$$

$$f_{\text{umbral}}(h) = \begin{cases} \text{clase "SI"} & \text{si } h \geq 0 \\ \text{clase "NO"} & \text{si } h < 0 \end{cases} \quad \leftarrow \text{umbral}$$